UNIVERSITAS NEGERI SURABAYA
FAKULTAS MATEMATIKA
DAN ILMU PENGETAHUAN ALAM
PRODI S1 SAINS DATA

Kampus Unesa 1
Jl. Ketintang, Gedung E2
Surabaya, 60231
datascience@unesa.ac.id
https://datascience.fmipa.unesa.ac.id

Analisis Pola dan Prediksi Penjualan Berbasis Data Time Series Menggunakan Metode ARIMA

Nadine Putri Aulia (24031554094), Putri Sofiyatus Salwa(24031554112), Cintiya Agustin Nareswari (24031554218)
Dosen Pengampu MK:
Ulfa Siti Nuraini, S.Stat., M.Stat., & Siska Puspitaningsih, S.Kom., M.Kom.
Kelas 2024B
Program Studi Sains Data, Universitas Negeri Surabaya

Abstrak

Forecasting penjualan penting dilakukan untuk membantu perencanaan dan pengambilan keputusan bisnis. Penelitian ini bertujuan membangun model forecasting revenue menggunakan metode Autoregressive Integrated Moving Average (ARIMA). Dataset yang digunakan adalah Global Retail Sales Dataset dari Kaggle yang terdiri dari 5.000 transaksi penjualan retail global periode 2023–2025. Data revenue diagregasi menjadi data time series mingguan sebanyak 130 periode pengamatan. Tahapan penelitian meliputi preprocessing data, exploratory data analysis (EDA), uji stasioneritas menggunakan Augmented Dickey-Fuller (ADF Test), identifikasi parameter ARIMA menggunakan grafik ACF dan PACF, pemodelan, forecasting, serta evaluasi model menggunakan MAE, RMSE, dan MAPE. Hasil penelitian menunjukkan bahwa data telah stasioner dengan nilai p-value sebesar 0,0023 sehingga tidak memerlukan differencing tambahan. Model terbaik yang diperoleh adalah ARIMA(1,0,1) dengan nilai AIC sebesar 2512,303. Evaluasi model menghasilkan nilai MAE sebesar 38649,69, RMSE sebesar 50108,36, dan MAPE sebesar 24,89%. Hasil forecasting menunjukkan revenue penjualan 12 minggu mendatang cenderung stabil pada kisaran 192 ribu per minggu. Dengan demikian, metode ARIMA cukup efektif digunakan untuk forecasting revenue penjualan jangka pendek.
Kata kunci: ARIMA, forecasting, revenue, time series, penjualan

BAB 1 Pendahuluan

A. Latar Belakang

Penjualan merupakan salah satu aspek penting dalam kegiatan bisnis yang sering mengalami fluktuasi dari waktu ke waktu. Perusahaan sering menghadapi kesulitan dalam memprediksi jumlah penjualan di masa depan karena adanya ketidakpastian permintaan. Data penjualan yang tersimpan secara historis umumnya berbentuk time series sehingga diperlukan analisis untuk memahami pola tren dan perubahan yang terjadi. Tanpa adanya analisis yang tepat, perusahaan berisiko mengalami kesalahan dalam perencanaan penjualan, seperti kelebihan atau kekurangan stok yang dapat memengaruhi efisiensi operasional perusahaan (Sinaga, 2023).

Permasalahan dalam prediksi penjualan dapat berdampak langsung pada pengelolaan persediaan dan proses operasional bisnis. Ketidakakuratan dalam forecasting dapat menyebabkan meningkatnya biaya penyimpanan, terganggunya

Kampus Unesa 1
Jl. Ketintang, Gedung E2
Surabaya, 60231
datascience@unesa.ac.id
https://datascience.fmipa.unesa.ac.id

distribusi produk, hingga kesalahan dalam pengambilan keputusan bisnis. Oleh karena itu, diperlukan metode yang mampu melakukan forecasting penjualan berdasarkan data historis secara lebih sistematis. Penelitian oleh Pathak et al. (2025) menunjukkan bahwa metode forecasting berbasis time series dapat membantu proses perencanaan bisnis dengan memanfaatkan pola historis data penjualan.

Salah satu metode yang banyak digunakan dalam forecasting time series adalah ARIMA (AutoRegressive Integrated Moving Average). Metode ARIMA mampu memodelkan pola data berdasarkan hubungan nilai sebelumnya dan error pada periode terdahulu. Selain itu, ARIMA memiliki tahapan analisis yang sistematis melalui uji stasioneritas, identifikasi parameter menggunakan ACF dan PACF, serta evaluasi hasil forecasting. Penelitian oleh Liu et al. (2021) menjelaskan bahwa ARIMA efektif digunakan pada data time series non-musiman dan mampu menghasilkan prediksi yang baik berdasarkan pola historis data. Penelitian Fang (2025) juga menunjukkan bahwa metode ARIMA dapat digunakan untuk forecasting penjualan e-commerce jangka pendek dengan tingkat akurasi yang memadai. Berdasarkan permasalahan tersebut, penelitian ini menggunakan dataset transaksi penjualan e-commerce dari Kaggle untuk melakukan forecasting revenue menggunakan metode ARIMA sehingga diharapkan dapat membantu dalam memahami pola revenue penjualan serta mendukung pengambilan keputusan bisnis.

B. Rumusan Masalah

Berdasarkan latar belakang yang telah dijelaskan, penelitian ini memiliki beberapa rumusan masalah sebagai berikut:

1. Bagaimana karakteristik pola perubahan revenue penjualan berdasarkan data time series pada *Global Retail Sales Dataset*?
2. Bagaimana penerapan metode ARIMA dalam membangun model forecasting revenue penjualan berdasarkan data historis?
3. Bagaimana performa model ARIMA dalam memprediksi revenue penjualan berdasarkan hasil evaluasi model menggunakan metrik MAE, RMSE, dan MAPE?

C. Tujuan Penelitian

Berdasarkan rumusan masalah yang telah disusun, tujuan penelitian ini adalah sebagai berikut:

1. Menganalisis karakteristik pola perubahan revenue penjualan berdasarkan data time series pada *Global Retail Sales Dataset*.
2. Menerapkan metode ARIMA untuk membangun model forecasting revenue berdasarkan data historis penjualan.
3. Mengevaluasi performa model ARIMA dalam memprediksi revenue menggunakan metrik MAE, RMSE, dan MAPE.

Kampus Unesa 1
Jl. Ketintang, Gedung E2
Surabaya, 60231
datascience@unesa.ac.id
https://datascience.fmipa.unesa.ac.id

BAB 2 Metodologi Penelitian

A. Penjelasan Dataset

Dataset yang digunakan dalam penelitian ini adalah Global Retail Sales Dataset yang diperoleh dari platform Kaggle. Dataset dapat diakases melalui tautan berikut: https://www.kaggle.com/datasets/hamza0027/global-retail-sales-dataset . Dataset ini terdiri dari 5.000 transaksi penjualan retail global yang dirancang untuk merepresentasikan kondisi bisnis e-commerce modern secara realistis. Data mencakup berbagai informasi transaksi seperti tanggal transaksi, kategori produk, negara, metode pembayaran, quantity, revenue, profit, customer rating, serta sales channel. Selain itu, dataset memiliki atribut waktu berupa order_date sehingga sesuai digunakan dalam analisis data time series dan forecasting penjualan menggunakan metode ARIMA.

Dataset dipilih karena memiliki struktur data yang lengkap, data transaksi yang terurut berdasarkan waktu, serta mendukung analisis pola penjualan dan prediksi revenue pada periode mendatang. Pada penelitian ini, data revenue diagregasi berdasarkan periode mingguan sehingga membentuk data runtun waktu (*time series*) mingguan yang digunakan dalam proses exploratory data analysis (EDA), pengujian stasioneritas, identifikasi parameter ARIMA, hingga forecasting revenue penjualan.

B. Variabel Penelitian

Variabel yang digunakan dalam penelitian ini berasal dari dataset transaksi penjualan e-commerce. Namun, pada proses forecasting menggunakan metode ARIMA, penelitian difokuskan pada variabel tanggal transaksi (*order_date*) dan revenue penjualan (*revenue*). Variabel *order_date* digunakan sebagai indeks waktu dalam pembentukan data time series, sedangkan variabel *revenue* digunakan sebagai variabel yang diprediksi pada proses forecasting revenue mingguan.

Tabel 1. Variabel Penelitian

Nama Variabel	Keterangan
Order Date	Tanggal transaksi penjualan
Revenue	Pendapatan transaksi penjualan

C. Metode Arima

Autoregressive Integrated Moving Average (ARIMA) merupakan salah satu metode analisis *time series* yang digunakan untuk melakukan prediksi berdasarkan pola data historis. Metode ARIMA menggabungkan komponen *Autoregressive* (AR), *Integrated* (I), dan *Moving Average* (MA) untuk memodelkan hubungan data berdasarkan urutan

Kampus Unesa 1
Jl. Ketintang, Gedung E2
Surabaya, 60231
datascience@unesa.ac.id
https://datascience.fmipa.unesa.ac.id

waktu. (Fang, 2025) menyatakan bahwa ARIMA banyak digunakan dalam *forecasting* penjualan *e-commerce* karena mampu memanfaatkan pola historis data untuk menghasilkan prediksi jangka pendek yang baik pada kondisi data yang relatif stabil. Menurut (Liu et al., 2021), ARIMA memiliki tiga parameter utama yaitu *p* (*autoregressive*), *d* (*differencing*), dan *q* (*moving average*). Parameter *p* menunjukkan jumlah lag pada komponen *autoregressive*, parameter *d* menunjukkan tingkat *differencing* agar data menjadi stasioner, sedangkan parameter *q* menunjukkan jumlah lag pada komponen *moving average*. Penentuan parameter dilakukan melalui identifikasi *Autocorrelation Function* (ACF), *Partial Autocorrelation Function* (PACF), serta pemilihan model terbaik menggunakan nilai *Akaike Information Criterion* (AIC). Pada penelitian ini, metode ARIMA digunakan untuk melakukan *forecasting revenue* penjualan berdasarkan data historis *Global Retail Sales Dataset*.

D. Uji Stasioneritas

Sebelum dilakukan pemodelan menggunakan metode ARIMA, data time series terlebih dahulu harus memenuhi asumsi stasioneritas. Data dikatakan stasioner apabila nilai rata-rata, varians, dan autokorelasi relatif konstan sepanjang waktu. Uji stasioneritas penting dilakukan karena metode ARIMA bekerja secara optimal pada data yang bersifat stasioner (Pathak et al., 2025). Pada penelitian ini, pengujian stasioneritas dilakukan menggunakan metode *Augmented Dickey-Fuller Test* (ADF Test) untuk mengetahui apakah data revenue telah memenuji asumsi tersebut. Kriteria pengambilan keputusan pada ADF Test adalah sebagai berikut:

1. Jika nilai p-value < 0.05, maka H0 ditolak dan data dinyatakan stasioner.
2. Jika nilai p-value >0.05, maka H0 diterima dan data dinyatakan tidak stasioner.

Apabila data belum stasioner, maka dilakukan proses *differencing* hingga data memenuhi asumsi stasioneritas. Setelah data dinyatakan stasioner, proses analisis dilanjutkan ke tahap identifikasi parameter ARIMA menggunakan grafik ACF (*Autocorrelation Function)* dan PACF *(Partial Autocorrelation Function).*

E. Metrik Evaluasi

Evaluasi model dilakukan untuk mengukur tingkat akurasi hasil prediksi revenue mingguan menggunakan metode ARIMA. Pada penelitian ini, evaluasi model dilakukan dengan membandingkan nilai aktual data pengujian (*testing data*) dengan hasil prediksi (*forecast*) yang dihasilkan model. Proses evaluasi dilakukan menggunakan beberapa metrik kesalahan, yaitu *Mean Absolute Error* (MAE), *Root Mean Squared Error* (RMSE), dan *Mean Absolute Percentage Error* (MAPE). Ketiga metrik tersebut dipilih karena umum digunakan dalam evaluasi model forecasting time series dan mampu memberikan gambaran mengenai tingkat kesalahan prediksi model dari berbagai sudut pandang.

1. Mean Absolute Error (MAE)

   Mean Absolute Error (MAE) digunakan untuk mengukur rata-rata selisih absolut antara nilai aktual dengan nilai hasil prediksi. Nilai MAE menunjukkan seberapa besar rata-rata kesalahan prediksi yang dihasilkan model tanpa memperhatikan arah error. Semakin kecil nilai MAE, maka semakin baik kemampuan model dalam

Kampus Unesa 1
Jl. Ketintang, Gedung E2
Surabaya, 60231
datascience@unesa.ac.id
https://datascience.fmipa.unesa.ac.id

melakukan forecasting karena selisih antara data aktual dan data prediksi semakin kecil. MAE juga termasuk metrik evaluasi yang mudah dipahami karena nilai error dinyatakan dalam satuan yang sama dengan data asli. Perhitungan MAE pada penelitian ini dilakukan menggunakan fungsi mean_absolute_error() dari library *Scikit-learn* pada Python.

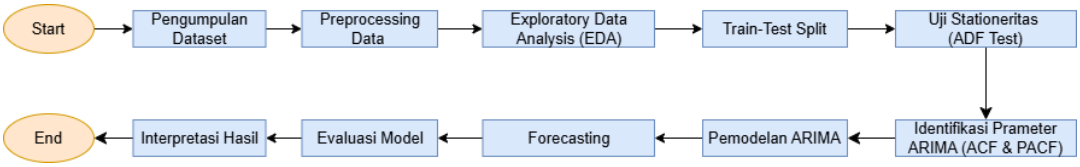
2. Root Mean Squared Error (RMSE)

   Root Mean Squared Error (RMSE) digunakan untuk mengukur tingkat kesalahan prediksi model berdasarkan akar kuadrat dari rata-rata error kuadrat. RMSE memberikan penalti yang lebih besar terhadap error bernilai tinggi karena proses perhitungan menggunakan kuadrat selisih antara nilai aktual dan prediksi. Nilai RMSE yang kecil menunjukkan bahwa model memiliki tingkat error yang rendah dan mampu menghasilkan prediksi yang mendekati data aktual (Fang, 2025). Metrik ini banyak digunakan pada penelitian forecasting karena sensitif terhadap kesalahan prediksi yang besar sehingga dapat menunjukkan kestabilan model dalam memprediksi data time series. Pada penelitian ini, nilai RMSE dihitung menggunakan fungsi mean_squared_error() dari library *Scikit-learn* yang kemudian diakarkan menggunakan library *NumPy*.

3. Mean Absolute Percentage Error (MAPE)

   Mean Absolute Percentage Error (MAPE) digunakan untuk mengukur tingkat kesalahan prediksi dalam bentuk persentase terhadap data aktual. MAPE mempermudah interpretasi hasil evaluasi karena nilai error dinyatakan dalam persen sehingga lebih mudah dipahami. Semakin kecil nilai MAPE, maka model dianggap semakin baik dalam melakukan forecasting. MAPE sering digunakan dalam penelitian prediksi penjualan, demand forecasting, maupun forecasting e-commerce karena dapat menunjukkan tingkat akurasi model secara relatif terhadap data aktual. Pada penelitian ini, nilai MAPE dihitung menggunakan fungsi mean_absolute_percentage_error() dari library *Scikit-learn* pada Python.

F. Pipeline Penelitian



Gambar 2.1 Tahapan Penelitian

Tahapan penelitian disusun untuk menggambarkan alur proses analisis data penjualan hingga menghasilkan *forecasting revenue* menggunakan metode ARIMA. Pipeline penelitian yang digunakan telah disesuaikan dengan tahapan pengerjaan *project* dan proses analisis *time series* pada penelitian ini.

1. Pengumpulan Dataset

   Tahap awal penelitian dilakukan dengan mengumpulkan dataset *Global Retail Sales Dataset* yang diperoleh dari Kaggle. Dataset berisi data transaksi penjualan seperti

Kampus Unesa 1
Jl. Ketintang, Gedung E2
Surabaya, 60231
datascience@unesa.ac.id
https://datascience.fmipa.unesa.ac.id

order_date, *revenue*, *quantity*, kategori produk, wilayah penjualan, dan variabel pendukung lainnya. Dataset digunakan sebagai sumber data utama dalam proses analisis dan prediksi *revenue*.

2. Preprocessing Data
   Tahap *preprocessing* dilakukan untuk mempersiapkan data sebelum proses analisis. Proses ini meliputi pengecekan *missing value*, pengecekan data duplikat, konversi tipe data tanggal ke format *datetime*, pengurutan data berdasarkan waktu, proses agregasi data, serta identifikasi *outlier*. Tahap ini bertujuan menghasilkan data yang lebih terstruktur dan siap digunakan pada tahap analisis berikutnya
3. Exploratory Data Analysis (EDA)
   Tahap *Exploratory Data Analysis* (EDA) dilakukan untuk memahami karakteristik data sebelum dilakukan proses pemodelan. Analisis dilakukan menggunakan beberapa visualisasi data untuk mengamati pola tren, distribusi data, fluktuasi penjualan, serta mengidentifikasi kemungkinan adanya *outlier* pada data.
4. Train-Test Split
   Data yang telah melalui proses *preprocessing* selanjutnya dibagi menjadi data *training* dan data *testing*. Data *training* digunakan untuk membangun model, sedangkan data *testing* digunakan untuk menguji kemampuan model dalam melakukan prediksi terhadap data yang belum pernah digunakan sebelumnya.
5. Uji Stasioneritas
   Sebelum dilakukan pemodelan menggunakan ARIMA, data diuji menggunakan *Augmented Dickey-Fuller Test* (ADF Test). Pengujian ini bertujuan untuk mengetahui apakah data telah memenuhi asumsi stasioneritas yang diperlukan dalam analisis *time series*.
6. Identifikasi Parameter ARIMA (ACF dan PACF)
   Tahap identifikasi parameter dilakukan menggunakan grafik *Autocorrelation Function* (ACF) dan *Partial Autocorrelation Function* (PACF). Tahap ini bertujuan menentukan parameter model ARIMA dan membandingkan beberapa kandidat model yang akan digunakan
7. Pemodelan ARIMA
   Tahap pemodelan dilakukan dengan membangun model ARIMA berdasarkan parameter yang diperoleh pada tahap sebelumnya. Model digunakan untuk mempelajari pola historis pada data *time series*
8. Forecasting
   Model yang telah dibangun selanjutnya digunakan untuk melakukan prediksi atau *forecasting* terhadap nilai *revenue* pada periode berikutnya.
9. Evaluasi Model
   Tahap evaluasi dilakukan untuk mengukur performa model dalam menghasilkan prediksi. Evaluasi dilakukan menggunakan metrik pengukuran kesalahan prediksi dan analisis residual untuk mengetahui kualitas model yang dibangun
10. Interpretasi Hasil
    Tahap terakhir dilakukan interpretasi terhadap hasil prediksi yang diperoleh. Interpretasi dilakukan untuk memahami pola data serta memperoleh informasi

Kampus Unesa 1
Jl. Ketintang, Gedung E2
Surabaya, 60231
datascience@unesa.ac.id
https://datascience.fmipa.unesa.ac.id

yang dapat mendukung pengambilan keputusan

BAB 3 Hasil dan Pembahasan

A. Karakteristik Data

1. Statistik Deskriptif

   Data yang digunakan dalam penelitian ini merupakan data revenue penjualan mingguan hasil agregasi dari Global Retail Sales Dataset. Setelah dilakukan agregasi berdasarkan periode mingguan, diperoleh sebanyak 130 data time series dengan rentang waktu Januari 2023 hingga Juni 2025.

Tabel 2. Statistik Deskriptif Revenue Mingguan

Statistik	Nilai
Jumlah Data	130
Mean	192.169,10
Standar Deviasi	43.386,39
Minimum	33.302,39
Kuartil 1	168.425,86
Median	193.759,63
Kuartil 3	220.851,80
Maksimum	290.729,85

Berdasarkan hasil statistik deskriptif, rata-rata revenue mingguan sebesar 192.169,10 dengan standar deviasi sebesar 43.386,98 yang menunjukkan bahwa data memiliki fluktuasi yang cukup tinggi. Nilai minimum revenue sebesar 33.302,39 dan nilai maksimum sebesar 290.729,85 menunjukkan adanya variasi revenue yang cukup besar antarperiode pengamatan.

2. Missing Value dan Duplicate Data

   Pengecekan missing value dilakukan untuk mengetahui apakah terdapat data kosong pada dataset yang dapat memengaruhi proses analisis. Berdasarkan hasil pengecekan, seluruh variabel memiliki nilai missing value sebesar 0 sehingga tidak diperlukan proses imputasi data.

   Selain itu, pengecekan duplicate data juga dilakukan untuk memastikan tidak terdapat data transaksi yang tercatat lebih lebih dari satu kali. Hasil pengecekan menunjukkan bahwa jumlah duplicate data sebesar 0 sehingga seluruh data dapat digunakan dalam proses analisis.

B. Preprocessing

Tahap preprocessing dilakukan untuk mempersiapkan data sebelum digunakan dalam proses analisis time series dan pemodelan ARIMA. Tahapan ini bertujuan untuk memastikan data memiliki format yang sesuai serta tidak mengandung permasalahan yang dapat memengaruhi hasil forecasting. Tahapan preprocessing penting untuk

Kampus Unesa 1
Jl. Ketintang, Gedung E2
Surabaya, 60231
datascience@unesa.ac.id
https://datascience.fmipa.unesa.ac.id

dilakukan karena metode ARIMA sensitif terhadap kualitas data dan memerlukan data time series yang terstruktur dengan baik (Pathak et al., 2025).

1. Transformasi Nama Kolom

   Tahap awal preprocessing dilakukan dengan menyeragamkan nama kolom menggunakan fungsi lower(). Proses ini bertujuan untuk mengubah seluruh nama atribut menjadi huruf kecil agar mempermudah proses pemanggilan atribut pada Python serta menghindari kesalahan penulisan akibat perbedaan huruf kapital. Hasil transformasi menunjukkan bahwa seluruh atribut berhasil diubah menjadi format huruf kecil seperti order_date, unit_price, discount_percent, dan customer_rating.

2. Konversi Tipe Data Datetime

   Atribut order_date pada dataset awal masih bertipe object sehingga belum dapat digunakan secara optimal dalam analisis time series. Oleh karena itu dilakukan konversi tipe data menjadi format datetime. Tahap ini penting dilakukan karena metode ARIMA membutuhkan data runtun waktu (*time series*) yang memiliki indeks waktu terstruktur agar proses agregasi, visualisasi, dan forecasting dapat dilakukan dengan benar. Berdasarkan hasil preprocessing, rentang waktu data dimulai dari tanggal 1 Januari 2023 hingga 19 Juni 2025.

3. Sorting Data Berdasarkan Waktu

   Setelah atribut tanggal berhasil dikonversi menjadi datetime, data kemudian diurutkan berdasarkan waktu transaksi. Proses sorting dilakukan agar data tersusun secara kronologis dari tanggal paling awal hingga tanggal terbaru. Pada analisis time series, urutan waktu sangat penting karena model ARIMA mempelajari pola historis berdasarkan urutan data sebelumnya.

4. Agregasi Revenue Mingguan

   Karena penelitian berfokus pada forecasting revenue mingguan, maka data transaksi harian diubah menjadi data agregasi mingguan menggunakan fungsi resample(). Proses agregasi dilakukan dengan menjumlahkan seluruh revenue dalam setiap minggu sehingga menghasilkan dataset time series mingguan. Hasil agregasi menunjukkan bahwa dataset memiliki 130 data mingguan. Contoh hasil dari agregasi mingguan ditunjukkan pada tabel berikut

Tabel 3. Hasil Agregasi Mingguan

Order_date	**Revenue**
2023-01-01	33302.39
2023-01-08	221710.44
2023-01-15	168424.52
2023-01-22	237224.22

Kampus Unesa 1
Jl. Ketintang, Gedung E2
Surabaya, 60231
datascience@unesa.ac.id
https://datascience.fmipa.unesa.ac.id

2023-01-29	225833.47

5. Deteksi Outlier Menggunakan Metode IQR

Tahap preprocessing berikutnya ialah mendeteksi outlier pada data revenue mingguan menggunakan metode *Interquartile Range* (IQR). Deteksi outlier dilakukan untuk mengetahui apakah terdapat data yang memiliki nilai terlalu jauh dari distribusi mayoritas data. Metode IQR menggunakan nilai kuartil pertama (Q1) dan kuartil ketiga (Q3) untuk menentukan batas bawah dan batas atas outlier. Data dikategorikan sebagai outlier apabila berada di bawah batas bawah atau di atas batas atas.

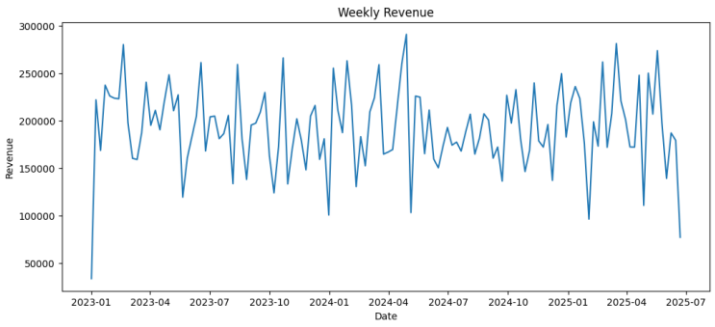
Tabel 4. Hasil Deteksi Outlier

Order_date	**Revenue**
2023-01-01	33302.39
2025-06-22	76854.94

Tabel 4 menunjukkan terdapat 2 outlier pada revenue mingguan. Outlier tersebut muncul karena nilai revenue pada minggu tersebut jauh lebih rendah dibandingkan mayoritas data lainnya. Namun, outlier tidak dihapus karena masih dianggap merepresentasikan kondisi transaksi yang valid dan tetap dibutuhkan dalam analisis forecasting.

C. *Exploratory Data Analysis*

1. Weekly *Revenue*



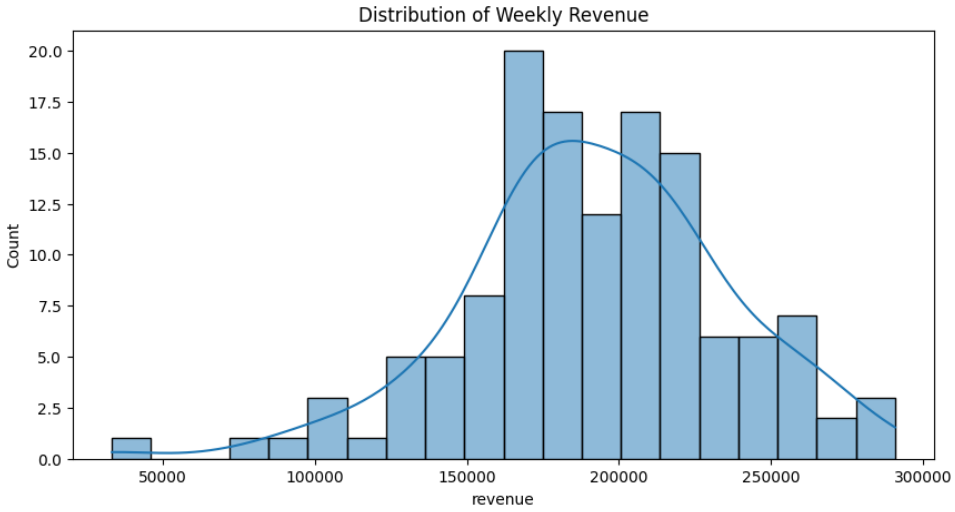
Gambar 3.1 Weekly Revenue

Berdasarkan grafik *Weekly Revenue*, terlihat bahwa revenue mingguan mengalami fluktuasi yang cukup tinggi selama periode Januari 2023 hingga Juni 2025. Sebagian besar nilai revenue berada pada rentang sekitar 100.000 hingga 290.000, meskipun terdapat beberapa periode dengan nilai yang lebih rendah yang teridentifikasi sebagai outlier. Grafik juga menunjukkan adanya kenaikan dan penurunan revenue yang terjadi secara tidak beraturan dari minggu ke minggu,

Kampus Unesa 1
Jl. Ketintang, Gedung E2
Surabaya, 60231
datascience@unesa.ac.id
https://datascience.fmipa.unesa.ac.id

sehingga mengindikasikan bahwa pola penjualan bersifat dinamis. Kondisi tersebut menunjukkan bahwa revenue mengalami variasi yang cukup besar antarperiode dan tidak membentuk tren kenaikan maupun penurunan yang konsisten selama periode pengamatan.

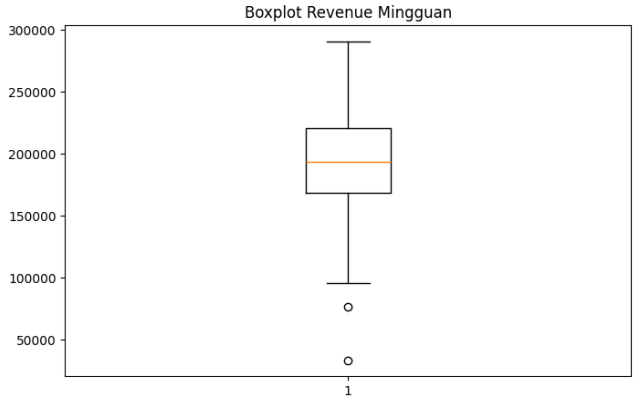
2. Histogram Revenue



Gambar 3.2 Distribusi Revenue Mingguan

Histogram menunjukkan bahwa sebagian besar nilai *revenue* terkonsentrasi pada rentang sekitar 160.000–230.000. Bentuk distribusi terlihat cukup mendekati distribusi normal meskipun terdapat sedikit kemiringan pada bagian kiri distribusi akibat adanya beberapa nilai *revenue* yang rendah. Hal tersebut menunjukkan bahwa sebagian besar periode memiliki pola penjualan yang relatif berada di sekitar nilai rata-rata.

3. Boxplot Revenue



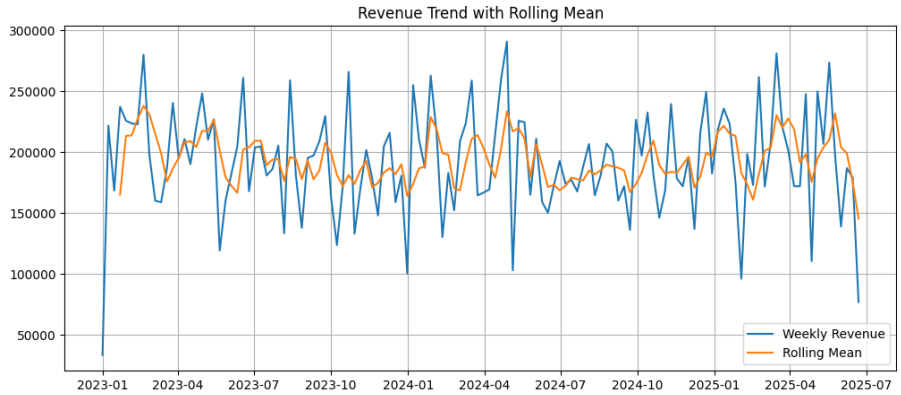
Gambar 3.3 Boxplot Revenue Mingguan

Berdasarkan *boxplot*, ditemukan dua data yang teridentifikasi sebagai

Kampus Unesa 1
Jl. Ketintang, Gedung E2
Surabaya, 60231
datascience@unesa.ac.id
https://datascience.fmipa.unesa.ac.id

outlier. Nilai tersebut berada pada tanggal 1 Januari 2023 sebesar 33.302,39 dan tanggal 22 Juni 2025 sebesar 76.854,94. Kedua nilai tersebut berada jauh di bawah rentang mayoritas data. Keberadaan *outlier* menunjukkan adanya periode tertentu dengan nilai *revenue* yang lebih rendah dibandingkan periode lainnya.

4. Revenue Trend with Rolling Mean



Gambar 3.4 Revenue Trend

Grafik *Revenue Trend with Rolling Mean* menunjukkan bahwa garis *rolling mean* memiliki pola yang relatif stabil dibandingkan data aktual yang berfluktuasi cukup tinggi. Meskipun terdapat kenaikan dan penurunan pada data mingguan, rata-rata bergerak menunjukkan pola yang cenderung konsisten. Hal ini mengindikasikan bahwa secara umum perubahan *revenue* tidak mengalami tren kenaikan atau penurunan yang ekstrem dalam jangka panjang.

D. *Train Test Split*

Sebelum dilakukan pemodelan ARIMA, data time series dibagi menjadi data training dan data testing menggunakan metode *train-test split* dengan proporsi 80:20. Pembagian data dilakukan berdasarkan urutan waktu agar karakteristik data time series tetap terjaga dan model dapat mempelajari pola historis revenue secara berurutan. Data training digunakan dalam proses pembentukan model ARIMA, sedangkan data testing digunakan untuk proses forecasting dan evaluasi model.

Tabel 5. Hasil Pembagian Data Train-Test Split

Jenis Data	Jumlah Data
Training Data	104
Testing Data	26

Berdasarkan hasil pembagian data, diperoleh total 130 data time series mingguan yang berasal dari hasil agregasi revenue berdasarkan periode waktu mingguan. Data tersebut kemudian dibagi menjadi 104 data training dan 26 data testing. Pembagian data dilakukan setelah proses agregasi revenue mingguan sehingga

Kampus Unesa 1
Jl. Ketintang, Gedung E2
Surabaya, 60231
datascience@unesa.ac.id
https://datascience.fmipa.unesa.ac.id

setiap baris data merepresentasikan total revenue penjualan pada satu periode minggu tertentu.

Tahapan train-test split dilakukan untuk memastikan model ARIMA dapat diuji menggunakan data yang belum pernah digunakan pada proses pelatihan model. Dengan demikian, performa forecasting yang dihasilkan dapat dievaluasi secara lebih objektif melalui perbandingan antara data aktual dan hasil prediksi model.

E. Uji Stasioneritas

Uji stasioneritas dilakukan sebelum pemodelan ARIMA untuk memastikan data time series memiliki rata-rata dan varians yang stabil dari waktu ke waktu. Pada penelitian ini digunakan metode Augmented Dickey-Fuller (ADF Test) terhadap data training revenue mingguan untuk mengetahui apakah data revenue telah memenuhi asumsi tersebut.

Tabel 6. Hasil Uji Stasioner

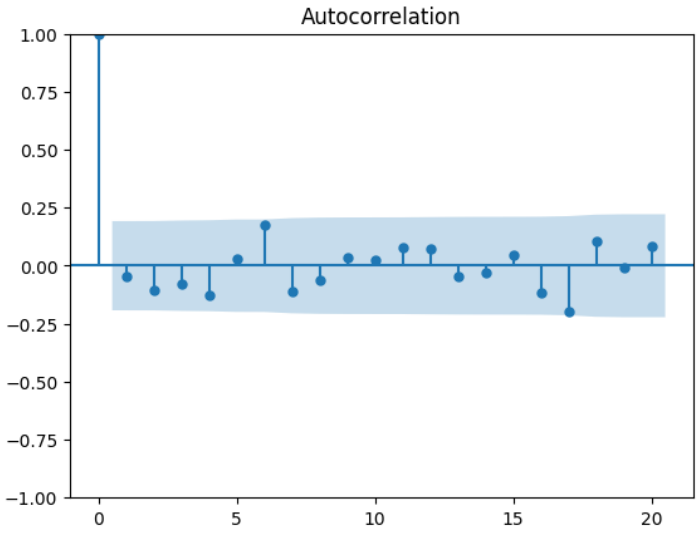
Parameter	Nilai
ADF Statistic	-3.864798
p-value	0.002309

Berdasarkan hasil tersebut diperoleh nilai ADF Statistic sebesar -3.864798 dan p-value sebesar 0.002309. Nilai p-value lebih kecil dari tingkat signifikansi 0,05 sehingga hipotesis nol (H0) ditolak. Dengan demikian, data revenue mingguan dinyatakan stasioner. Hasil ini menunjukkan bahwa data tidak memiliki tren yang menyebabkan perubahan rata-rata secara signifikan sepanjang waktu. Karena data sudah stasioner, maka proses differencing tidak diperlukan sehingga parameter differencing pada model ARIMA dapat ditetapkan sebesar d = 0.

F. Identifikasi Parameter ARIMA (ACF dan PACF)

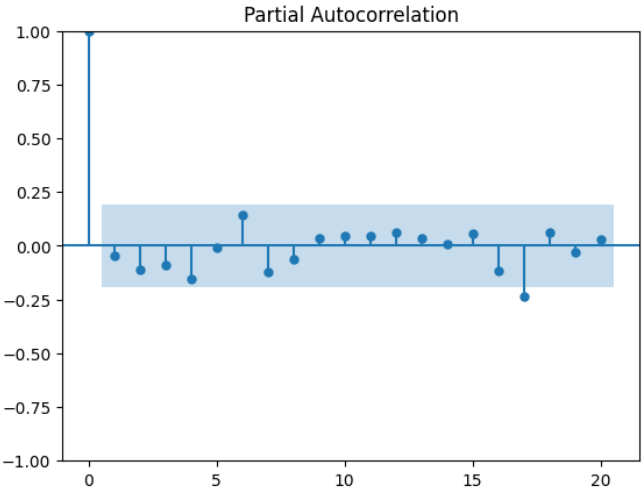
Tahap identifikasi parameter dilakukan untuk menentukan nilai parameter *p*, *d*, dan *q* pada model ARIMA. Penentuan parameter dilakukan melalui analisis grafik *Autocorrelation Function* (ACF), *Partial Autocorrelation Function* (PACF), serta perbandingan beberapa kandidat model menggunakan nilai *Akaike Information Criterion* (AIC). Berdasarkan hasil uji stasioneritas yang telah dilakukan pada tahap sebelumnya, data dinyatakan stasioner dengan nilai *p-value* sebesar 0,0023 (< 0,05), sehingga tidak memerlukan proses *differencing* dan parameter *d* ditetapkan sebesar 0. Selanjutnya, identifikasi parameter *p* dan *q* dilakukan menggunakan grafik ACF dan PACF.

Kampus Unesa 1
Jl. Ketintang, Gedung E2
Surabaya, 60231
datascience@unesa.ac.id
https://datascience.fmipa.unesa.ac.id



Gambar 3.5 Grafik Autocorrelation Function (ACF)

Grafik *Autocorrelation Function* (ACF) digunakan untuk mengidentifikasi parameter *Moving Average (q)* pada model ARIMA. Berdasarkan grafik ACF terlihat sebagian besar nilai korelasi berada dalam batas *confidence interval*. Hal ini menunjukkan tidak terdapat pola autokorelasi yang sangat kuat pada beberapa *lag*. Namun beberapa *lag* awal masih menunjukkan korelasi yang relatif kecil sehingga digunakan sebagai pertimbangan dalam pembentukan kandidat model.



Gambar 3.6 Grafik Partial Autocorrelation Function (PACF)

Grafik *Partial Autocorrelation Function* (PACF) digunakan untuk menentukan parameter *Autoregressive (p)*. Berdasarkan grafik PACF terlihat bahwa sebagian besar *lag* berada dalam batas *confidence interval* dan tidak menunjukkan pola lonjakan yang sangat signifikan. Oleh karena itu, beberapa kombinasi parameter diuji lebih lanjut melalui perbandingan kandidat model ARIMA.

Kampus Unesa 1
Jl. Ketintang, Gedung E2
Surabaya, 60231
datascience@unesa.ac.id
https://datascience.fmipa.unesa.ac.id

G. Pemodelan Arima

Setelah dilakukan identifikasi parameter menggunakan grafik ACF (Autocorrelation Function) dan PACF (*Partial Autocorrelation Function*), tahap selanjutnya adalah membangun model ARIMA untuk forecasting revenue penjualan. Pada penelitian ini, beberapa kandidat model ARIMA diuji untuk menentukan model terbaik berdasarkan nilai *Akaike Information Criterion* (AIC). Model dengan nilai AIC terkecil dipilih karena dianggap memiliki keseimbangan terbaik antara kompleksitas model dan kemampuan model dalam menyesuaikan data.

Tabel 7. Perbandingan Kandidat Model ARIMA

Model ARIMA	AIC
ARIMA (0,0,0)	2.890,190
ARIMA (1,0,0)	2.513,024
ARIMA (0,0,1)	2.512,788
ARIMA (1,0,1)	2.512,303
ARIMA (2,0,1)	2.513,420
ARIMA (1,0,2)	2.514,572
ARIMA (2,0,2)	2.514,035

Berdasarkan hasil perbandingan kandidat model ARIMA, diperoleh bahwa model ARIMA (1,0,1) memiliki nilai AIC terkecil yaitu sebesar 2.512,303 dibandingkan model lainnya. Oleh karena itu, model ARIMA (1,0,1) dipilih sebagai model terbaik dalam penelitian ini karena paling optimal dalam memodelkan pola revenue penjualan mingguan.

SARIMAX Results

Dep. Variable:	revenue	No. Observations:	104
Model:	ARIMA(1, 0, 1)	Log Likelihood	-1252.152
Date:	Wed, 27 May 2026	AIC	2512.303
Time:	14:41:54	BIC	2522.881
Sample:	0	HQIC	2516.589
	- 104		
Covariance Type:	opg		

	coef	std err	z	P>|z|	[0.025	0.975]
const	1.916e+05	2608.360	73.448	0.000	1.86e+05	1.97e+05
ar.L1	0.6139	0.352	1.746	0.081	-0.075	1.303
ma.L1	-0.7438	0.304	-2.443	0.015	-1.341	-0.147
sigma2	1.482e+09	0.003	5.06e+11	0.000	1.48e+09	1.48e+09

Ljung-Box (L1) (Q):	0.33	Jarque-Bera (JB):	8.28
Prob(Q):	0.57	Prob(JB):	0.02
Heteroskedasticity (H):	0.62	Skew:	-0.25
Prob(H) (two-sided):	0.17	Kurtosis:	4.29

Gambar 3.7 Hasil Pemodelan ARIMA (1,0,1)

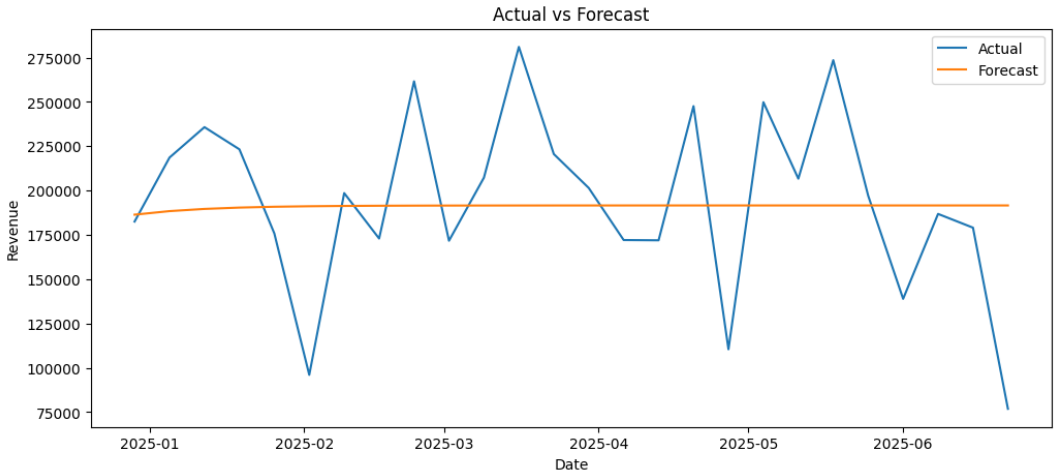
Kampus Unesa 1
Jl. Ketintang, Gedung E2
Surabaya, 60231
datascience@unesa.ac.id
https://datascience.fmipa.unesa.ac.id

Berdasarkan hasil pemodelan ARIMA(1,0,1), diperoleh nilai AIC sebesar 2.512,303 yang merupakan nilai terkecil dibandingkan kandidat model lainnya sehingga model ini dipilih sebagai model terbaik. Nilai koefisien autoregressive AR(1) sebesar 0,6139 menunjukkan adanya pengaruh revenue pada periode sebelumnya terhadap revenue saat ini. Selain itu, koefisien moving average MA(1) sebesar –0,7438 menunjukkan adanya pengaruh error pada periode sebelumnya terhadap model.

Hasil pengujian residual menggunakan Ljung-Box Test menunjukkan nilai probabilitas sebesar 0.57 (>0.05), yang mengindikasikan bahwa residual model tidak mengandung autokorelasi yang signifikan. Hal ini menunjukkan bahwa model ARIMA(1,0,1) telah mampu menangkap pola data time series dengan cukup baik dan layak digunakan untuk proses forecasting revenue penjualan.

H. Hasil Forecasting

Setelah model ARIMA(1,0,1) ditetapkan sebagai model terbaik berdasarkan nilai Akaike Information Criterion (AIC) terendah, tahap selanjutnya adalah melakukan forecasting pada data pengujian (testing data). Proses forecasting dilakukan menggunakan 26 data testing yang sebelumnya dipisahkan dari data training dengan proporsi 80:20. Pada tahap ini, model menghasilkan nilai prediksi revenue mingguan yang kemudian dibandingkan dengan nilai aktual untuk mengetahui kemampuan model dalam mengikuti pola data sebenarnya. Visualisasi perbandingan antara data aktual dan hasil forecasting dapat dilihat pada Gambar 3.8.



Gambar 3.8 Actual vs Forecast Revenue Mingguan

Berdasarkan gambar 3.8, terlihat bahwa garis forecast cenderung membentuk pola yang relatif stabil di kisaran revenue sekitar 190 ribu. Sementara itu, data aktual menunjukkan fluktuasi yang cukup tinggi dari minggu ke minggu. Hal ini menunjukkan bahwa model ARIMA yang digunakan mampu menangkap pola umum atau rata-rata pergerakan revenue, namun belum sepenuhnya mampu mengikuti perubahan ekstrem pada data aktual.

Pada beberapa periode terlihat perbedaan yang cukup jelas antara garis aktual

Kampus Unesa 1
Jl. Ketintang, Gedung E2
Surabaya, 60231
datascience@unesa.ac.id
https://datascience.fmipa.unesa.ac.id

dan forecast, terutama ketika terjadi lonjakan dan penurunan revenue yang signifikan. Sebagai contoh, pada sekitar bulan Mei 2025 data aktual mengalami peningkatan hingga lebih dari 250.000, sedangkan nilai forecast tetap berada di sekitar 190.000. Kondisi serupa juga terlihat pada akhir periode pengamatan ketika revenue aktual turun drastis hingga sekitar 75.000, namun hasil forecast masih berada pada kisaran yang relatif stabil. Meskipun demikian, model ARIMA(1,0,1) tetap dapat memberikan gambaran umum tren revenue mingguan dan cukup baik digunakan untuk melihat kecenderungan rata-rata data dalam jangka pendek. Model ini lebih optimal dalam menangkap pola stabil dibandingkan fluktuasi ekstrem pada data revenue.

Tabel 8. Hasil Actual dan Forecast

Periode	Actual Revenue	Forecast Revenue
1	182479.47	186377.42
2	218599.28	188385.90
3	235749.21	189618.99
4	223239.90	190376.03
5	175793.37	190840.81

Tabel 8 menunjukkan sebagian hasil perbandingan antara nilai aktual dan hasil forecast pada data testing. Berdasarkan tabel tersebut, terlihat bahwa hasil forecast memiliki nilai yang relatif mendekati data aktual, meskipun pada beberapa periode masih terdapat selisih prediksi yang cukup besar. Perbedaan ini dipengaruhi oleh fluktuasi revenue mingguan yang cukup tinggi sehingga model menghasilkan prediksi yang lebih halus dan stabil.

Pada penelitian ini, forecasting tidak hanya digunakan untuk memprediksi nilai masa depan, tetapi juga digunakan untuk mengevaluasi performa model. Oleh karena itu, hasil forecast dibandingkan dengan data aktual pada data testing. Setelah model dievaluasi dan menghasilkan performa yang cukup baik, model kemudian digunakan untuk melakukan prediksi revenue pada beberapa minggu mendatang.

I. Evaluasi Model

Evaluasi model dilakukan untuk mengetahui kemampuan model ARIMA(1,0,1) dalam melakukan prediksi *revenue*. Pengukuran performa dilakukan menggunakan MAE (*Mean Absolute Error*), RMSE (*Root Mean Squared Error*), MAPE (*Mean Absolute Percentage Error*), serta *Ljung-Box Test* untuk mengevaluasi residual model.

Tabel 9. Hasil Evaluasi Model

Metrik	Nilai

Kampus Unesa 1
Jl. Ketintang, Gedung E2
Surabaya, 60231
datascience@unesa.ac.id
https://datascience.fmipa.unesa.ac.id

MAE	38649.69
RMSE	50108.36
MAPE	24.89%
Ljung-Box p-value	0.730

Berdasarkan hasil evaluasi, model ARIMA(1,0,1) menghasilkan nilai MAE sebesar 38649.69 dan RMSE sebesar 50108.36. Nilai tersebut menunjukkan masih terdapat selisih antara hasil prediksi dan data aktual, terutama pada periode yang mengalami perubahan *revenue* cukup tinggi. Hal ini menunjukkan model belum sepenuhnya mampu mengikuti fluktuasi data yang bersifat dinamis.

Nilai MAPE sebesar 24.89% menunjukkan tingkat kesalahan prediksi rata-rata berada pada kisaran 24.89%, sehingga model termasuk dalam kategori cukup baik untuk melakukan *forecasting revenue*. Selain itu, hasil *Ljung-Box Test* memperoleh *p-value* sebesar 0.730 (>0.05), yang menunjukkan residual bersifat acak (*white noise*) dan tidak memiliki autokorelasi signifikan. Hasil tersebut mengindikasikan bahwa model ARIMA(1,0,1) telah memenuhi asumsi residual yang baik dan layak digunakan untuk proses *forecasting*.

J. Forecast 12 Minggu Mendatang

Setelah diperoleh model terbaik yaitu ARIMA(1,0,1), model digunakan untuk melakukan forecasting revenue penjualan pada 12 minggu mendatang. Forecasting dilakukan berdasarkan pola historis revenue mingguan yang telah dipelajari oleh model ARIMA selama proses training.

Tabel 10.Hasil Forecast 12 Minggu Mendatang

Periode	Forecast Revenue
1	193.456,22
2	193.271,82
3	193.108,10
4	192.962,74
5	192.833,68
6	192.719,09
7	192.617,35
8	192.527,02
9	192.446,82
10	192.375,61
11	192.312,39
12	192.256,25

Berdasarkan hasil forecasting, nilai *revenue* untuk 12 minggu mendatang diprediksi berada pada kisaran 192.000–193.500 per minggu. Nilai prediksi

Kampus Unesa 1
Jl. Ketintang, Gedung E2
Surabaya, 60231
datascience@unesa.ac.id
https://datascience.fmipa.unesa.ac.id

menunjukkan kecenderungan menurun secara perlahan, dari sekitar 193.456 pada awal periode menjadi 192.256 pada akhir periode prediksi. Hal ini menunjukkan bahwa model ARIMA(1,0,1) memproyeksikan adanya penurunan yang relatif kecil, namun secara umum *revenue* tetap berada pada kondisi yang stabil tanpa perubahan yang ekstrem.

Selain itu, hasil forecasting menunjukkan bahwa pola *revenue* mingguan cenderung stabil meskipun pada data historis sebelumnya terdapat fluktuasi penjualan. Model ARIMA mampu menangkap pola utama pada data dan menghasilkan estimasi *revenue* yang konsisten pada periode mendatang. Dengan demikian, hasil prediksi tersebut dapat digunakan sebagai gambaran awal dalam mendukung perencanaan strategi penjualan maupun pengambilan keputusan bisnis dalam jangka pendek.

BAB 4 Kesimpulan dan Saran

A. Kesimpulan

Penelitian ini berhasil menerapkan metode ARIMA untuk melakukan forecasting revenue penjualan berdasarkan Global Retail Sales Dataset yang telah diagregasi menjadi data time series mingguan sebanyak 130 periode pengamatan. Hasil analisis menunjukkan bahwa revenue mingguan memiliki pola yang berfluktuasi tanpa tren yang kuat dengan rata-rata revenue sebesar 192.169,10. Uji stasioneritas menggunakan Augmented Dickey-Fuller (ADF) menghasilkan nilai ADF Statistic sebesar -3,864798 dan p-value sebesar 0,002309 (< 0,05), sehingga data dinyatakan stasioner dan tidak memerlukan proses differencing (d = 0). Berdasarkan identifikasi parameter menggunakan ACF, PACF, dan perbandingan nilai AIC, diperoleh model terbaik yaitu ARIMA(1,0,1) dengan nilai AIC sebesar 2512,303. Hasil Ljung-Box Test juga menunjukkan p-value sebesar 0,730 (> 0,05), yang mengindikasikan bahwa residual model bersifat acak dan tidak mengandung autokorelasi yang signifikan.

Evaluasi model menghasilkan nilai MAE sebesar 38.649,69, RMSE sebesar 50.108,36, dan MAPE sebesar 24,89%. Hasil tersebut menunjukkan bahwa model memiliki kemampuan yang cukup layak dalam melakukan forecasting revenue jangka pendek, meskipun belum mampu mengikuti fluktuasi ekstrem yang terjadi pada beberapa periode pengamatan. Forecasting untuk 12 minggu mendatang menunjukkan bahwa revenue diperkirakan berada pada kisaran 192.000–193.500 per minggu dengan kecenderungan menurun secara perlahan namun tetap relatif stabil. Dengan demikian, metode ARIMA(1,0,1) dapat digunakan sebagai pendekatan yang cukup efektif untuk memprediksi revenue penjualan dan memberikan informasi yang dapat mendukung perencanaan serta pengambilan keputusan bisnis.

B. Saran

Penelitian selanjutnya disarankan menggunakan dataset dengan periode waktu yang lebih panjang serta mempertimbangkan variabel lain yang dapat memengaruhi revenue, seperti kategori produk, metode pembayaran, dan wilayah penjualan. Selain itu, dapat dilakukan perbandingan dengan metode forecasting lain seperti SARIMA, Prophet, atau Long Short-Term Memory (LSTM) untuk mengetahui model yang memiliki

Kampus Unesa 1
Jl. Ketintang, Gedung E2
Surabaya, 60231
datascience@unesa.ac.id
https://datascience.fmipa.unesa.ac.id

tingkat akurasi lebih baik. Dengan pengembangan tersebut, hasil forecasting diharapkan mampu menangkap pola fluktuasi revenue secara lebih akurat dan memberikan informasi yang lebih optimal dalam mendukung pengambilan keputusan bisnis.

Daftar Pustaka

Fang, J. (2025). *E-commerce retail sales trend analysis and prediction based on the ARIMA model. Proceedings of the 2025 International Conference on Financial Risk and Investment Management (ICFRIM 2025).* https://doi.org/10.2991/978-94-6463-748-9_87

Liu, Z., Zhu, Z., Gao, J., & Xu, C. (2021). Forecast methods for time series data: A survey. *IEEE Access, 9*, 91896–91908. https://doi.org/10.1109/ACCESS.2021.3091162

Pathak, V. K., Tiwari, T., Chaurasia, M., & Bagri, G. (2025). *Study of demand forecasting using time-series analysis (ARIMA).* https://doi.org/10.21203/rs.3.rs-6801470/v1

Sinaga, S. A. (2023). Implementasi metode ARIMA (*autoregressive integrated moving average*) untuk prediksi penjualan mobil. *Journal Global Technology Computer, 2*(3), 102–109. https://doi.org/10.47065/jogtc.v2i3.4013

Lampiran

A. Kontribusi Anggota

NO	Nama	NIM	Kontribusi
1	Nadine Putri Aulia	24031554094	Berkontribusi pada penyusunan laporan bagian penjelasan dataset, uji stasioneritas, karakteristik data, train test split, pemodelan ARIMA, forecast 12 minggu mendatang, serta penyusunan daftar pustaka, mengerjakan implementasi kode pada bagian train-test split, pemodelan ARIMA, dan forecasting lanjutan. Selain itu turut berkontribusi dalam pencarian dataset, pencarian literatur, revisi laporan, serta diskusi kelompok secara bersama.
2	Putri Sofiyatus Salwa	24031554112	Berkontribusi pada penyusunan latar belakang, variabel penelitian, metrik evaluasi, preprocessing, uji stasioneritas hasil, hasil forecasting, kesimpulan, dan kontribusi anggota, mengerjakan implementasi kode preprocessing,

Kampus Unesa 1
Jl. Ketintang, Gedung E2
Surabaya, 60231
datascience@unesa.ac.id
https://datascience.fmipa.unesa.ac.id

			evaluasi model, serta interpretasi hasil forecasting. Selain itu turut berkontribusi dalam pencarian dataset, pencarian literatur, revisi laporan, serta diskusi kelompok secara bersama.
3	Cintiya Agustin Nareswari	24031554218	Berkontribusi pada penyusunan rumusan masalah, tujuan penelitian, metode ARIMA, pipeline penelitian, exploratory data analysis (EDA), identifikasi parameter ARIMA (ACF dan PACF), evaluasi model, saran, serta tautan Google Colab, mengerjakan implementasi kode visualisasi EDA, ACF-PACF, dan analisis evaluasi model. Selain itu turut berkontribusi dalam pencarian dataset, pencarian literatur, revisi laporan, serta diskusi kelompok secara bersama.

B. Tautan Google Colab :
https://colab.research.google.com/drive/1QyrVCejeNlpQahT7auHuizLNU4cvxukQ?usp=sharing#scrollTo=jLsitNx8V30s